Задача 1. Теория: экономика контекста

(а) Вывод формулы стоимости

На каждом шаге $t \in \{1, \dots, T\}$ агент обрабатывает контекст, состоящий из системного промпта S, описания инструментов D и накопленной истории H_t. По условию, размер истории на шаге t аппроксимируется как $H_t \approx h \cdot t$.

Учитывая, что кэшированный префикс $(S+D)$ стоит долю α от базовой цены $p_{in} = 1$, стоимость обработки токенов на шаге t равна:

$$c_t = \alpha(S + D) + h \cdot t$$

Общая стоимость за T шагов C вычисляется как сумма стоимостей на каждом шаге:

$$C = \sum_{t=1}^{T} c_t = \sum_{t=1}^{T} (\alpha(S + D) + h \cdot t) = \alpha(S + D)T + h \sum_{t=1}^{T} t$$

Сумма арифметической прогрессии равна $\sum_{t=1}^{T} t = \frac{T(T+1)}{2} = \frac{T^2}{2} + \frac{T}{2}$. При достаточно большом количестве шагов T линейным слагаемым можно пренебречь. Таким образом, делается **приближение**: $\frac{T(T+1)}{2} \approx \frac{T^2}{2}$.

Итоговая аппроксимированная формула общей стоимости:

$$C \approx \alpha(S + D)T + h\frac{T^2}{2}$$

(б) Расчет стоимости C для различных α

Дано: $S = 2\,000$, $D = 55\,000$, $h = 1\,500$, $T = 40$.
Вычислим постоянные компоненты:

- Базовая стоимость префикса: $S + D = 2\,000 + 55\,000 = 57\,000$ токенов.
- Стоимость истории: $h\frac{T^2}{2} = 1\,500 \cdot \frac{1600}{2} = 1\,200\,000$ токенов.

Случай 1: $\alpha = 1$ **(без скидки на кэширование)**

- Стоимость префикса за T шагов: $1 \cdot 57\,000 \cdot 40 = 2\,280\,000$.
- Общая стоимость $C = 2\,280\,000 + 1\,200\,000 = 3\,480\,000$.
- Доля истории: $\frac{1\,200\,000}{3\,480\,000} \approx 0,3448$ или **34,5%**.

Случай 2: $\alpha = 0,1$ **(со скидкой на кэширование префикса)**

- Стоимость префикса за T шагов: $0,1 \cdot 57\,000 \cdot 40 = 228\,000$.
- Общая стоимость $C = 228\,000 + 1\,200\,000 = 1\,428\,000$.

- Доля истории: $\frac{1\,200\,000}{1\,428\,000} \approx 0,8403$ или **84,0%**.

Вывод: При эффективном кэшировании ($\alpha = 0,1$) абсолютное большинство затрат (84%) приходится на обработку растущей истории. Следовательно, наибольшую экономию теперь дает рычаг h **(уменьшение объема сохраняемой истории на каждом шаге)**, например, через суммаризацию или обрезку старых сообщений.

(в) Сравнение вариантов: все инструменты против RAG-поиска

Дано: $d = 300$ (описание одного инструмента). Кэш не учитывается ($\alpha = 1$). Нам нужно найти условие, при котором контекст варианта B меньше контекста варианта A: $D_B < D_A$.

- **Вариант A (все описания):** $D_A = N \cdot d = 300N$
- **Вариант B (инструмент поиска +** k **результатов):** $D_B = s + k \cdot d = 500 + 5 \cdot 300 = 2\,000$

Составим неравенство:

$$2\,000 < 300N \implies N > \frac{2000}{300} = 6,66...$$

Так как N должно быть целым числом, минимальное количество инструментов, при котором вариант B становится дешевле на каждом шаге, равно $N = 7$.

(г) Анализ точности и ограничений варианта B

Точность варианта B равна $Recall@5(N) \cdot A(5) = 0,95 \cdot 0,90 = 0,855$.
Точность варианта A равна $A(N)$.

Вариант B перестает выигрывать по точности (или начинает проигрывать), когда точность варианта A становится выше:

$$A(N) > 0,855$$

Таким образом, порог составляет **0,855** (или 85,5%).

Факторы, делающие модель слишком оптимистичной для варианта B:

1. **Скрытые затраты на дополнительные шаги (**T**).** Чтобы вариант B сработал, агент должен сначала потратить один или несколько шагов (вызовов LLM) на формирование поискового запроса и вызов инструмента поиска. Это увеличивает как общее количество шагов T, так и объем накопленной истории H_t, что приводит к скрытым затратам, не учтенным в простом сравнении D_A и D_B.
2. **Падение** $Recall$ **в реальных задачах.** Модель предполагает константный высокий $Recall@5 = 0,95$. В реальности, если пользовательский запрос сформулирован нечетко или не содержит ключевых слов, поисковой инструмент (особенно на базе векторного поиска) может не найти нужные инструменты, снижая реальный $Recall$ и общую надежность пайплайна значительно ниже теоретических 85,5%.